

河北工业大学研究生学位论文中期报告

论文题目 基于图学习的单细胞多组学细胞亚群分析研究

类别	博士 ☐ 硕士 ☒
所属学院	人工智能与数据科学学院
学科专业	计算机技术
研究方向	生物信息学
导师姓名	董瑶
学号	202232803012
姓名	张佳雪

2024 年 7 月 1 日

一、问题的提出

在复杂的生物过程中，异质性同时存在于基因组、转录组、表观组、免疫组等多个层面，基因相同的细胞可能具有不同的DNA甲基化、基因表达，克隆扩增^{[1]-[3]}等，常常需要基于单个细胞进行多个组学技术联合，才能更加准确地将它们分成不同亚群，揭示更深层的生物学机制^{[4]-[6]}。单细胞多组学研究可以促进发现不同组学数据之间的相关性和互补性，增强人类对细胞内各种生物过程调控机制的认识。

但是，单细胞多组学聚类面临着巨大的挑战。首先就是数据的异质性和高噪声^[7]，每个组学都有其差异，如：scRNA-seq数据受到环境RNA和dropout问题的影响，而表观基因组数据（如scATAC-seq）涉及稀疏二进制或近二进制测量^[8]。此外，测量到的特征数量差异也很大，空间和蛋白质数据只有数十个或数百个，而scRNA-seq数据的特征数量有数千个不等。

为了解决上述问题，研究人员付出了相当大的努力。整合不同的单细胞多组学的方法可分为四个主要阶段。基于矩阵分解和基于因子分析的方法，如SLNMF^[9]，MOFA+^[10]，scAI^[11]，Seurat v4^[12]，scABC^[13]，Liger^[14]，UnionCom^[15]。基于编码器的方法，如DCCA^[16]，scMVAE^[17]，scMVP^[18]。基于学习的对比方法，如scMCs^[19]。基于图的方法，如scMoGNN^[20]，GLUE^[21]。

基于矩阵分解和因子分析的方法能直接获得组学间共享的浅层低维信息，但很难得到组学之间的非线性关系^{[22]-[23]}。随着深度学习在计算机等领域的发展完善，研究者引入编码器方法来探讨组学之间的复杂关系。这些方法通过建立不同的编码器^{[24][25]}，如零膨胀负二项ZINB编码器^[26]，VAE与概率高斯混合模型^{[27]-[28]}等，迭代地学习数据中的底层表示，进一步揭示不同组学的分布，然后通过解码器重建数据，最大限度地保留信息，降低噪声。更进一步地，研究人员在编码器之间实现了对比学习^{[29]-[30]}，从scRNA-seq和scATAC-seq数据中提取共享信息，使单细胞多组学数据复杂关联和相互作用得以展现。但多组学数据往往包含不同特征之间的互信息。将这些互信息传递到编码器的重构过程中较为困难，导致重构结果可能损失了一些特征间的关联信息。于是，学者又引入图学习^{[31]-[33]}进行单细胞多组学数据的聚类，能够捕获关系，包括细胞

河北工业大学研究生学位论文中期报告

之间的相似性和连通性，从而更准确地描述内部结构。但仍然缺乏对多组学数据中共享信息的挖掘和利用，对组学信息的挖掘需要进一步的细化。

而随着测序技术的不断发展，单细胞多组学的另一个主要挑战——数据规模的扩大^[34]也在引起人们的关注。图网络在聚合丰富信息的同时，它们的计算成本呈指数级增长。现有的聚类方法对图信息的利用不足，网络计算成本高，计算资源的消耗增加，聚类性能受到限制。

不少学者将多组学作为一种多视图的方式进行处理。在多视图分析领域，现有的多视图聚类算法主要基于图模型，在实际中应用于大规模数据集^[35]，耗时且具有挑战性。为了提高效率，学者提出利用锚点和数据之间的关系来表示所有数据点之间的关系。目前，锚选择有两种策略：启发式抽样^[36]^[38]和自适应抽样^[39]^[41]。启发式抽样策略已被应用于单细胞scRNA-seq数据领域，研究人员引入了一种可扩展和有效的锚图聚类算法^[42]。该算法在保持准确性的同时，提高了最先进的共识聚类方法的运行时间和扩展性。然而，这种策略通常依赖于K-means或随机抽样，确定的锚点可信度有限。EOMSC-CA^[41]应用了高效的多视图子空间聚类和共识锚学习。研究人员将锚点选择过程和图构造过程统一进行联合优化，得到了具有代表性的共识锚图。但是，这种方法在多组学领域不能完全适用。首先，在学习过程中，这类方法只学习图的结构信息。而在单细胞领域，主要依靠特征（基因、peak）区分细胞类型。其次，该方法从不同的角度学习共享的表示，完全忽略了差异。在多组学领域，细胞的特征表达在不同的分子水平上差异很大，需要去除分子差异的共享表示。

结合上面的问题，本课题将自适应锚图和图表示学习建立在同一框架下，利用提取到的特异信息和共享高阶信息对scRNA-seq和scATAC-seq数据整合进行聚类。

二、课题研究内容

2.1 主要研究内容

本课题开发了一种基于锚图的单细胞多组学细胞聚类方法(An Anchor Graph-based Method for Cell Clustering from Integrated scRNA-seq and scATAC-seq Data ,

河北工业大学研究生学位论文中期报告

scAGCI), 用于整合 scRNA-seq 和 scATAC-seq 数据。scAGCI 为全面展示细胞的异质性, 学习了不同组学的结构信息和特征信息, 并挖掘组学特征之间的生物调节关系。受多视图领域里锚点学习的启发, 提出了一种协同优化锚图和图表示学习的策略, 在有效地从多个组学中提取特异信息和共享信息来表示 scRNA-seq 和 scATAC-seq 数据的同时, 降低了计算成本。

2.2 研究的创新性

(1) 针对现有多组学聚类方法对组学的图信息提取和利用不足的问题。设计了提取组学结构信息和特征信息的锚点图和挖掘共享高阶信息的层次化图注意力模块。

对于单细胞多组学聚类, 细胞-细胞、细胞-特征以及特征和特征的生物关系都蕴含着丰富的生物信息, 来帮助进一步区分细胞类型。比如scRNA-seq数据中的基因、scATAC-seq数据中的峰, 以及峰与基因之间调控作用。本研究重视这些生物信息, 尤其是基因与峰之间的调控关系的挖掘, 这在现有的研究中很少见, 但对整合单细胞多组学具有重要意义。于是, 课题设计提取组学结构特征这些特异信息的自适应锚点图学习来构建组学特异图和共享图, 再层次化图注意力模块挖掘共享高阶信息来补全完善组学信息。

(2) 针对图网络计算成本高, 导致的计算资源消耗增加以及组学稀疏噪声的问题。研究设计了一个动态锚点学习策略来优化单细胞多组学的特定表示和共享表示。

图网络在聚合丰富信息的同时, 它们的计算成本呈指数级增长。现有的聚类方法由于对图信息的利用不足, 网络计算成本度高, 导致计算资源的消耗增加, 聚类性能受到限制。通过锚点降低图网络的大小, 大大节省了计算资源。另外, 为了更好地提取到代表组学数据的锚点, 本文采用GCN, 通过一个统一、双向的循环来优化每个组学和共享组学的锚点及其锚点图。在有效降低计算成本的同时, 也缓解了组学数据的稀疏性。

三、研究进展及阶段性成果

scAGCI, 基于锚图的单细胞多组学细胞聚类模型图如图3.1所示。模型图主要包

括多视图子空间锚点协同优化模块、层次化图注意力模块和共性融合补全模块。首先，多视图子空间锚点协同优化模块在不同组学和特征拼接的组学数据中使用K-means算法计算簇中心作为初始锚点，以初始锚点和细胞为节点，构建组学特异性图和共享图，其次通过最小化原始节点和锚点之间的Frobenius范数损失，利用图卷积网络学习节点表示和更新锚点。再设计层次化图注意力模块提取共享图中组学高阶信息 Z_s ；共性融合补全聚类模块中设计共性融合补全算子，用 Z_s' 补全 Z_1, Z_2 信息得到 Z_{im1}, Z_{im2} ，最后对 Z_{im1}, Z_{im2}, Z_s' 融合进行聚类。




图3.1 基于锚图的单细胞多组学细胞聚类模型图

3.1.1 多视图子空间锚点协同优化模块

1) 特异锚图的建立

建立各个组学数据的特异锚图。为方便描述，scRNA-seq数据视为 X_1 。scATAC-seq视为 X_2 ，它们的特征拼接数据为 X_m ，则有 $X_i \in \mathbb{R}^{d_i \times n}$ ， $i = 1, 2$ 表示特征维度 d_i ，细胞个数为 n 的 i 视图， $X_m \in \mathbb{R}^{(d_1+d_2) \times n}$ 表示特征维度为 $d_1 + d_2$ ，细胞个数为 n 的特征拼接视图。假定在同一子空间内的数据点之间具有线性关系。子空间聚类可以表示为：

$$\min_Z L(X, XZ) + \rho \varphi(Z), \quad (3.1)$$

其中， $L(\cdot)$ 代表损失函数， $\varphi(\cdot)$ 正则化函数， $Z \in \mathbb{R}^{n \times n}$ 代表细胞之间的相似矩阵， ρ 是

河北工业大学研究生学位论文中期报告

平衡正则化影响的权重系数。

定义二部图为 $B_i = (X_i, Y_i, Z_i)$, $i = 1, 2$, 二部图锚点子空间聚类可以表示为

$$\min_{Z_i} L(X_i, Y_i Z_i) + \rho \varphi(Z_i), \quad (3.2)$$

其中, $Y_i \in \mathbb{R}^{d_i \times m}$, $i = 1, 2$ 为 X_1 和 X_2 的特异锚点矩阵, 初始化时, 使用K-means^[43]算法从所有视图的 n 个细胞中选取 m 个作为初始锚点 Y_0 。 $Z_i \in \mathbb{R}^{m \times n}$ 是 Y_i 和 X_i 之间的相似矩阵, B_i 是锚图。在本课题中使用Frobenius范数作为损失函数。于是, 上述二部图锚点子空间聚类被表示为

$$\begin{aligned} \min_{Z_i} & \|X_i - Y_i Z_i\|_F^2 + \rho \|Z_i\|_F^2 \\ \text{s. t.} \quad & Z_i \geq 0, \quad Z_i^T \mathbf{1} = \mathbf{1}, \end{aligned} \quad (3.3)$$

其中, $\mathbf{1}$ 是全为1的列向量, 保证了 Z_i 的每一列加起来等于1。由此 X_1 和 X_2 得到组学特异锚图 B_1 和 B_2 。

2) 共享锚图的建立

为了使组学的信息充分融合, 得到视图之间的互补信息, 在多个组学视图数据之间建立共享图。定义锚点投影矩阵 $W_i \in \mathbb{R}^{d_i \times d}$ 用来对齐共享锚点 Y_s 特征维度 d 与 i 视图的原始组学数据的特征维度 d_i , 于是共享图建立:

$$\begin{aligned} \min_{\alpha, W_i, Z_s, Y_s} & \sum_{i=1}^v \alpha_i^2 \|X_i - W_i Y_s Z_s\|_F^2 + \|Z_s\|_F^2 \\ \text{s. t.} \quad & \alpha^T \mathbf{1} = 1, \alpha_i \geq 0, W_i^T W_i = I_d, Y_s^T Y_s = I_m, Z_s \geq 0, Z_s^T \mathbf{1} = \mathbf{1}, \end{aligned} \quad (3.4)$$

其中, v 是输入视图的数量, α_i 是平衡各视图之间影响的权重系数, α 为 α_i 形成的列向量。 X_i 是 i 视图的原始特征矩阵, $Y_s \in \mathbb{R}^{d \times m}$ 是视图之间的共享锚点, m 是共享锚点个数。 Z_s 是锚点集合和视图间的共享矩阵, $B_s = (X_m, Y_s, Z_s)$ 为共享图。

3) 锚点学习和图表示学习表示协同优化

现存基于锚图的多视图子空间聚类方法严重依赖于初始化锚点的策略, 其锚点选择和图表示学习过程相互分离, 导致最终聚类结果边界不清晰。针对这一问题, 本文提出锚点选择和图表示学习协同优化的策略去学习共享和特异组学视图, 控制变量来进行优化。

河北工业大学研究生学位论文中期报告

图卷积网络(Graph Convolution Network, GCNs)^[44]学习图表示:

$$H^{(l+1)} = \sigma(D'^{-\frac{1}{2}}A'D'^{-\frac{1}{2}}D'^{-\frac{1}{2}}H^{(l)}W'^{(l)}), \quad (3.5)$$

σ 为激活函数Relu, 实现图卷积网络的非线性变换, $A' = A + I$, A 为建立图的邻接矩阵, 向邻接矩阵添加了单位矩阵 I 后得到 A' , D' 为 A' 的度矩阵, $H^{(l)}$ 为第 l 层的特征表示, $W'^{(l)}$ 为第 l 层的权重参数矩阵。GCN通过邻接矩阵向邻居节点传播特征结构信息。

1. 更新图表示

本课题中使用两层 GCNs 为例。

$$Z_{GCN} = \text{softmax}\left(D'^{-\frac{1}{2}}A'D'^{-\frac{1}{2}}D'^{-\frac{1}{2}}\text{Relu}(D'^{-\frac{1}{2}}A'D'^{-\frac{1}{2}}D'^{-\frac{1}{2}}H^{(1)}W'^{(1)})W'^{(2)}\right). \quad (3.6)$$

以共享锚图为例, 则对应锚图表示可由公式(3.7)得到,

$$\min_{Z_s} \sum_{i=1}^v Y_s^T Z_{GCN}, \quad (3.7)$$

2. 更新 W_i : 固定 Z_s , Y_s 和 α , 对 W_i 进行优化:

$$\min_{W_i} \sum_{i=1}^v \alpha_i^2 \|X_i - W_i Y_s Z_s\|_F^2 + \|Z_s\|_F^2 \quad \text{s.t.} \quad W_i^T W_i = I_d. \quad (3.8)$$

由于 W_i 独立于各视图, 上面的公式可简化为

$$\max_{W_i} \text{Tr}[W_i^T X_i Z_s^T Y_s^T] \quad \text{s.t.} \quad W_i^T W_i = I_d, \quad (3.9)$$

其中 $\text{Tr}(\cdot)$ 是矩阵的迹。

3.更新 Z_s : 固定 α , W_i , Y_s , 对 Z_s 进行优化, 公式可以简化为:

$$\min_{Z_s} \sum_{i=1}^v \alpha_i^2 \text{Tr}[Z_s Z_s^T - 2X_i^T W_i Y_s Z_s] \quad \text{s.t.} \quad Z_s \geq 0, Z_s^T \mathbf{1} = \mathbf{1}. \quad (3.10)$$

4.更新 Y_s : 固定 Z_s , W_i 和 α , 对 Y_s 优化, 可以简化为:

$$\max_{Y_s} \text{Tr}[Y_s^T \sum_{i=1}^v \alpha_i^2 W_i^T X_i Z_s^T] \quad \text{s.t.} \quad Y_s^T Y_s = I_m, \quad (3.11)$$

5.更新 α : 固定 Z_s , W_i , Y_s , 对 α 进行优化:

$$\begin{aligned} \min_{\alpha} \sum_{i=1}^v \alpha_i^2 \text{Tr}[Z_s - 2W_i Z_s Z_s] + \|Z_s\|_F^2 \\ \text{s.t.} \quad \alpha^T \mathbf{1} = 1, \quad \alpha_i \geq 0. \end{aligned} \quad (3.12)$$

定义 $O_i = \|X_i - W_i Y_s Z_s\|_F^2$, 通过Cauchy-Buniakowsky-Schwarz^[44]不等式得到最佳的 α_i :

河北工业大学研究生学位论文中期报告

$$\alpha_i = \frac{1/O_i}{\sum_{i=1}^p 1/O_i}. \quad (3.13)$$

通过上面的方式，所有变量自动交替更新直到收敛，就可以获得共享锚点表示 Z_s ，使用同样的方法，更新公式3，可以得到特异图表示 Z_1, Z_2 。

3.1.2 层次化图注意力模块

目前研究重视对单细胞多组学数据先验知识（基因相互作用和峰调控关系）的引入，如scMoGNN和GLUE。而本课题更关注于从数据本身挖掘特征间的关系，比如基因和峰的调控关系，以丰富得到的组学表示。

利用带遮掩的图注意力网络。图注意力层输入共享图的节点特征集合 $H = \{h_1, h_2, \dots, h_n\}, h_i \in \mathbb{R}^F$ ，输出为 $H' = \{h'_1, h'_2, \dots, h'_n\}, h'_j \in \mathbb{R}^{F'}$ ，其中 n 为细胞个数， h_i, h'_i 分别是输入和输出的节点嵌入， F, F' 是输入和输出的节点嵌入维度，归一化后输入节点嵌入可表示为

$$\vec{H} = \{\vec{h}_1, \vec{h}_2, \dots, \vec{h}_n\}, \vec{h}_i \in \mathbb{R}^F. \quad (3.14)$$

输出节点嵌入为

$$\vec{H}' = \{\vec{h}'_1, \vec{h}'_2, \dots, \vec{h}'_n\}, \vec{h}'_N \in \mathbb{R}^{F'}. \quad (3.15)$$

为了计算每个邻居节点的权重，通过一个共享权重 W 应用于每个节点，注意力系数如下：

$$e_{ij} = a(W\vec{h}_i, W\vec{h}_j), \quad (3.16)$$

a 表示节点 j 相对于节点 i 的重要性。归一化权重系数：

$$a_{ij} = \text{softmax}(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{k \in 2n} \exp(e_{ik})}, \quad (3.17)$$

$a(\cdot)$ 使用 LeakyReLU, 则有

$$a_{ij} = \frac{\exp(\text{LeakyRelu}(\vec{a}^T [W\vec{h}_i \parallel W\vec{h}_j]))}{\sum_{k \in N_i} \exp(\text{LeakyRelu}(\vec{a}^T [W\vec{h}_i \parallel W\vec{h}_k]))}, \quad (3.18)$$

$\vec{a}$ 是由 a 计算的归一化注意力系数， N_i 是图中节点的邻域， $\parallel$ 是串联操作。得到节点 i 的表示：

$$\vec{h}'_i = \sigma(\sum_{j \in N_i} \vec{a}_{ij} W\vec{h}_j), \quad (3.19)$$

使用多头注意力机制，再取均值：

$$\vec{h}_i' = \sigma(\frac{1}{K} \sum_{k=1}^K \sum_{j \in N_i} \vec{a}_{ij} W \vec{h}_j), \quad (3.20)$$

其中， K 是多头注意力头部的数量。

层次化图注意力模块通过迭代更新共享图中所有节点中隐藏状态的方式来进行表示学习。因此，该网络具备学习共享图高阶邻居节点信息的能力，能捕获共享图中节点与其邻居节点特征之间的关系，获得基因和峰的调控关系。通过这一模块得到高阶共享图表示 Z_s' 。

3.1.3 共性融合补全模块

在共性融合补全模块中，设计了共性融合补全算子来整合组学特异表示 $Z_i, i = 1, 2$ 和高阶共享表示 Z_s' ，以丰富特异组学：

$$Z_{im1} = Z_s' \odot Z_1 \quad (3.21)$$

$$Z_{im2} = Z_s' \odot Z_2 \quad (3.22)$$

$\odot$ 表示哈达玛算子， Z_{im1} 和 Z_{im2} 是补全后的特异图表示

最后对 Z_{im1}, Z_{im2} 整合进行聚类：

$$Z_{final} = \theta Z_{im1} + (1 - \theta) Z_{im2}, \text{ s.t. } 0 < \theta < 1. \quad (3.23)$$

3.1.4 算法时间复杂度分析

由于应用了锚点图学习，scAGCI 具有较低时间复杂度。它主要涉及四个变量的迭代更新：共享或组学特异图表示 Z_{im1}, Z_{im2}, Z_s 、锚点矩阵 Y_1, Y_i, Y_s 、权重系数 α_i 和锚点投影矩阵 W_i ，这些变量分别使用矩阵分解、图学习和矩阵乘法进行更新。其计算复杂度为 $O(n^2 + nml + ml^2 + m^3)$ ，其中 $m \ll n, l \ll n$ 。图注意力模块的计算复杂度为 $O(m^2)$ ，通用融合完成模块主要涉及矩阵乘法和线性计算，其计算复杂度为 $O(nm)$ 。因此scAGCI的计算复杂度主要由 $O(n^2)$ 决定。

3.2 阶段性成果

3.2.1 实验结果及分析

3.2.1.1 数据集及其预处理

(1)细胞系混合物数据集 (CellMix): CellMix是包含配对的1047个细胞scRNA-seq和scATAC-seq数据的小型数据集, 这些数据来自SNARE-seq^[46]混合培养的人类BJ、H1、K562和GM12878 细胞系。使用Seurat包^[12]在scRNA-seq数据集中保留1047个细胞中表达量最高的500个基因, 并在scATAC-seq中保留基因上游和基因体100 kb内的7136个峰。

(2)人类外周血单核细胞数据集(PBMC-3K): PBMC-3K 包含配对的3012个细胞的scRNA-seq和scATAC-seq。首先删除200个质量较差的细胞(线粒体比例大于25%, 阈值低于200)。然后利用Azimuth软件^[47]预测2900个细胞, 并删除数量少于5个细胞的细胞类型数据, 最终获得2874个细胞和14种细胞类型。为了提高效率, 使用Seurat 包^[12]在scRNA-seq数据集中保留表达量最高的1500个基因, 并在scATAC-seq数据集中保留基因上游和基因体100 kb内的11,063个峰。

(3)小鼠皮肤数据集 (Mouse-Skin): Mouse-Skin包含34,774个细胞的大型数据集。使用SHARE-seq^[48]从成年小鼠皮肤获得配对的scRNA-seq和scATAC-seq的数据。该数据集已预处理, 不再进行其他操作。

得到的数据集信息如表3.1所示。

表3.1 3个真实单细胞多组学数据集的信息统计

名称	细胞数量	scRNA-seq基因数量	scATAC-seq峰数量	细胞类型
CellMix	1047	500	7136	4
PBMC-3K	2874	1500	11063	14
Mouse-skin	34774	2000	35943	23

3.2.1.2 实验设置

本文初始化预训练GCN并将其设置为2层。scRNA-seq数据的隐藏层维度从[500, 1000, 1500, 2000]中选择, scATAC-seq数据的隐藏层维度从[1000, 2000, 3000, 4000, 5000]中选择。初始学习率为0.01, 迭代次数为1000次, 权重衰减设置为5e-3, 并使用Adam

河北工业大学研究生学位论文中期报告

优化器进行学习。锚点的数量需要在[10k, 20k, 30k, 40k, 50k, 60k, 70k]范围内确定,其中k表示数据集中的簇数。对于GAT, 选择从1到3的层数, 多头注意力默认设置为3。

至于比较方法, 采用在原始论文中产生最佳结果的参数。所有算法都运行在配备Intel(R) Xeon(R) Gold 6348 CPU @ 2.60GHz处理器、100GB Memory和一块NVIDIA A30 TENSOR CORE GPU的机器上。scAI、EOMSC-CA和JSNMF在MATLAB版本 R2021a)上实现。MOFA+和Liger都在Rstudio (版本2021) 上实现。

3.2.1.3 评价指标

实验选取准确率 (Accuracy, ACC)、归一化互信息^[49] (Normalized Mutual Information, NMI)、宏观F1分数^[50] (Macro F1-score, F1)、精确率 (Precision Rate, Precision)、召回率 (Recall Rate, Recall)、调整兰德指数 (Adjusted Rand Index, ARI) 和轮廓系数 (Silhouette Coefficient, SC)^[51]作为聚类效果的评价指标。

准确度: ACC定义为正确预测细胞类型的细胞数与总预测细胞数的比值, 直接体现算法预测出的细胞类型与真实细胞类型间的整体差异, 需要进入数据的真实标签进行计算, 取值范围为[0,1]。准确度的具体计算方式如式(3.24)所示。

$$ACC = \frac{\sum_{i=1}^n \delta(l_i, \text{map}(x_i))}{n}, \quad (3.24)$$

其中, l_i 是细胞 x_i 对应的真实细胞类型标签, n 为细胞数量, $\text{map}(x_i)$ 是细胞 x_i 通过 $\text{map}(\cdot)$ 生成对应的预测标签, 函数 δ 定义如式(3.25)所示。

$$\delta(x, y) = \begin{cases} 1 & l = x \\ 0 & l \neq x \end{cases}. \quad (3.25)$$

归一化互信息: NMI显示了两个聚类结果的相近程度, 取值范围为[0,1], 值越大表明聚类结果越相近, 该评价指标的计算方式如式(3.26)所示

$$NMI(X, Y) = \frac{2I(X; Y)}{H(X) + H(Y)}. \quad (3.26)$$

其中, $H(\cdot)$ 表示一个簇的熵, $I(X; Y)$ 代表了随机变量X和随机变量Y的互信息, 即知道其中一个随机变量导致另一个随机变量减少的不确定性。NMI的取值范围为[0,1], 数值越大聚类效果越好。

精确率, 召回率: Precision和Recall是n个类别精确度和召回率的平均值, 取值范

河北工业大学研究生学位论文中期报告

围均为[0,1]，评价指标的计算方式如式(3.27)-式(3.30)所示：

$$\text{Precision}_i = \frac{TP}{TP+FP} \quad (3.27)$$

$$\text{Recall}_j = \frac{TP}{TP+FN} \quad (3.28)$$

$$\text{Precision} = \frac{1}{n} \sum_{i=1}^n \text{Precision}_i \quad (3.29)$$

$$\text{Recall} = \frac{1}{n} \sum_{j=1}^n \text{Recall}_j \quad (3.30)$$

宏观F1分数：F1是 n 个类别精确度和召回率的加权平均值，取值范围为[0,1]，该评价指标的计算方式为：

$$\begin{aligned} F1 &= \frac{2 \times (\text{Precision} \cdot \text{Recall})}{\text{Precision} + \text{Recall}} \\ &= \frac{2}{n} \sum_{i=1}^n \frac{TP_i}{2TP_i + FP_i + FN_i}. \end{aligned} \quad (3.31)$$

ARI是样本真实标签和预测标签的相似程度，如果真实标签结果为 $U = \{u_1, u_2, \dots, u_s\}$ ，预测结果为 $v = \{v_1, v_2, \dots, v_r\}$ ，则可计算一个矩阵，矩阵中第 i 行，第 j 列的元素 e_{ij} 代表细胞类型 u_i 和 v_j 中同样本的数目，则有 $e_{i \cdot} = \sum_{j=1}^r e_{ij}$ 和 $e_{\cdot j} = \sum_{i=1}^s e_{ij}$

$$\text{ARI} = \frac{\sum_{ij} \binom{e_{ij}}{2} - [\sum_i \binom{e_{i \cdot}}{2}] [\sum_j \binom{e_{\cdot j}}{2}] / \binom{n}{2}}{\frac{1}{2} [\sum_i \binom{e_{i \cdot}}{2} + \sum_j \binom{e_{\cdot j}}{2}] - [\sum_i \binom{e_{i \cdot}}{2}] [\sum_j \binom{e_{\cdot j}}{2}] / \binom{n}{2}}. \quad (3.32)$$

轮廓系数：Silhouette coefficient 通过比较样本和其所在细胞类型簇内的其他细胞的相似度与该样本和其他细胞类型簇内细胞的相似度，衡量该聚类结果的适当程度。对于样本 x ，轮廓系数的计算方式为：

$$sc(x) = \frac{b(x) - a(x)}{\max\{a(x), b(x)\}}, \quad (3.33)$$

其中 $a(x)$ 代表样本 x 到其所在细胞簇中各个样本距离的平均值， $b(x)$ 代表该样本到其他细胞簇中样本距离的平均值。所以所有样本的轮廓系数可以定义为：

$$SC = \frac{1}{n} \sum_{x=1}^n sc(x), \quad (3.34)$$

其中， n 表示所有样本的个数，轮廓系数的取值范围是[-1,1]，数值越大说明聚类效果

越好。

3.2.1.4 对比结果及分析

为了验证scAGCI模型在单细胞多组学数据上的聚类性能，以ACC, NMI, F-score, precision, Recall, ARI, S-score为评价指标，在CellMix、PBMC_3k、Mouse_skin数据集上与13种单细胞多组学聚类算法进行对比分析，各算法的具体介绍如下：

K-means^[43]: 一种传统的聚类方法。

Liger^[14]: 一种基于非负矩阵分解的单细胞多组学整合方法。

MOFA+^[10]: 一种基于多组学因子分析的单细胞多组学分析方法。

scAI^[11]: 一种假定转录组和表观基因组的数据矩阵共享潜在空间的加权线性函数，从而推断潜在的细胞类型的方法。

UnionCom^[15]: 将多组学数据投影到一个公共的嵌入空间中，并通过一个全局尺度参数来匹配复杂的非线性特征，并在这个嵌入空间中对细胞或其他生物学实体进行聚类。

DCCA^[16]: 将不同的组学投射到相应的低维空间中，并使用“Teacher-Student”机制来融合多组学数据。

scMVAE^[17]: scMVAE模型采用三种策略来学习数据融合和聚类的联合潜在特征。scMVAE-Direct连接每个组学的原始特征，scMVAE-NN整合了从不同组学中提取的低维特征，而scMVAE-PoE则联合多个专家模型来估计联合后验分布。

JSNMF^[52]: 将不同的组学数据分解为不同的潜在空间，并通过共识图学习多组学数据的一致信息。

scMVP^[18]: 一种单细胞多视图分析器，通过利用聚类一致性约束的多视图变分自编码器模型(VAE)来自动学习scRNA-seq和scATAC-seq数据的共同潜在表示。

EOMSC-CA^[41]: 一种基于多视图锚点学习的计算方法，利用不同视图的信息学习一致性信息来聚类。

scMCs^[19]: 一种基于单细胞多组学数据融合的聚类方法，用于联合建模单细胞转录组数据和表观遗传数据的共性和特异特征的分布情况。

表3.2-3.4展示了本文方法在三个数据集上，与13种其他聚类方法的结果。加粗的

河北工业大学研究生学位论文中期报告

值代表所有方法中最好的结果，下划线的值代表次优结果。

表3.2 CellMix数据集对比实验

算法	ACC	NMI	F1	Precision	Recall	ARI	SC
K-means	0.6705	0.5948	0.6300	0.6351	0.6249	0.4563	0.5932
Liger	0.8763	0.8333	0.8767	0.8900	0.8637	0.8637	0.6921
MOFA+	0.8956	0.8526	0.8960	0.8897	0.9023	0.8978	0.6907
scAI	0.6523	0.6122	0.6830	0.6415	0.7303	0.5450	0.6814
UnionCom	0.8510	0.7052	0.8815	0.8836	0.8795	0.6420	0.5236
DCCA	0.6566	0.6190	0.6502	0.6491	0.6513	0.5132	0.6395
scMVAE-POE	0.9423	0.8526	0.9344	0.9237	0.9453	0.8397	0.6788
scMVAE-NN	0.9389	0.8174	0.8804	0.8667	0.8946	0.8093	0.6532
scMVAE-Direct	0.9056	0.8110	0.8889	0.8746	0.9037	0.8115	0.6854
JSNMF	0.5263	0.2613	0.2295	0.5326	0.1463	0.1965	0.3015
scMVP	0.8687	0.8712	0.8711	0.8920	0.8514	0.8756	0.7032
EOMSC-CA	0.7831	0.7852	0.8420	0.8525	0.8318	0.7223	<u>0.7132</u>
scMCs	<u>0.9439</u>	<u>0.9073</u>	<u>0.9389</u>	<u>0.9330</u>	<u>0.9448</u>	<u>0.9391</u>	0.6664
scAGCI	0.9571	0.9479	0.9572	0.9562	0.9583	0.9522	0.7263

表3.3 PBMC-3k数据集对比实验

算法	ACC	NMI	F1	Precision	Recall	ARI	SC
K-means	0.4554	0.5678	0.3752	0.3837	0.3671	0.4835	0.4952
Liger	0.5396	0.5743	0.4271	0.4632	0.3962	0.4369	0.3691
MOFA+	0.4597	0.4189	0.4583	0.3916	0.5523	0.5735	0.5245
scAI	0.5609	0.6470	0.3960	0.4847	0.3347	0.5932	-0.0444
UnionCom	0.5094	0.6065	0.5295	0.5262	0.5328	0.4001	0.4698
DCCA	0.3909	0.5942	0.3616	0.3549	0.3686	0.4069	0.3865
scMVAE-POE	0.5640	0.6036	0.5220	0.5195	0.5246	0.4563	0.4987
scMVAE-NN	<u>0.5718</u>	<u>0.6112</u>	<u>0.6105</u>	<u>0.6113</u>	0.6097	0.6373	<u>0.5586</u>
scMVAE-Direct	0.5318	0.5052	0.5853	0.5936	0.5773	0.4442	0.2198
JSNMF	0.4612	0.4163	0.3073	0.2947	0.3211	0.2846	0.2456
scMVP	0.3527	0.5863	0.4489	0.4296	0.4700	<u>0.6451</u>	0.4625
EOMSC-CA	0.4412	0.4474	0.4720	0.3745	0.6383	0.3465	0.4936
scMCs	0.3855	0.5348	0.3903	0.3604	0.4257	0.5960	0.5292
scAGCI	0.6294	0.6963	0.6364	0.6514	<u>0.6220</u>	0.6579	0.5631

河北工业大学研究生学位论文中期报告

表3.4 Mouse-skin数据集对比实验

算法	ACC	NMI	F1	Precision	Recall	ARI	SC
K-means	0.4344	0.4652	0.4515	0.5144	0.4835	0.2368	0.1037
Liger	0.3047	0.2846	0.2481	0.2500	0.2463	0.2333	0.1078
MOFA+	0.4839	0.5149	0.4984	0.5031	0.4939	0.3026	0.1095
scAI	0.5217	0.4937	0.5076	0.4989	0.5167	<u>0.3437</u>	0.0081
UnionCom	-	-	-	-	-	-	-
DCCA	0.2887	0.2650	0.3241	0.2936	0.3619	0.2593	-0.0004
scMVAE-POE	<u>0.5463</u>	<u>0.5170</u>	<u>0.5916</u>	<u>0.5776</u>	0.6063	0.3300	0.0752
scMVAE-NN	0.5037	0.4932	0.5503	0.5459	0.5548	0.2950	0.1249
scMVAE-Direct	0.5412	0.5240	0.5801	0.5479	<u>0.6164</u>	0.3310	0.0794
JSNMF	0.1703	0.1401	0.1410	0.1425	0.1396	0.0872	0.2537
scMVP	0.3346	0.2936	0.3183	0.3223	0.3145	0.3063	0.3033
EOMSC-CA	0.3843	0.3063	0.3975	0.4539	0.3536	0.1986	0.3023
scMCs	0.3428	0.4332	0.2440	0.2140	0.2838	0.2608	<u>0.4088</u>
scAGCI	0.5631	0.5259	0.6134	0.5978	0.6300	0.3567	0.4360

通过观察分析，得出以下结果：

(1) scAGCI学习到的图表示效果显著。观察表明，与其他方法相比，scAGCI始终能获得令人满意的embedding结果。在CellMix数据集上，与次优方法scMCs相比，本文方法在CellMix数据集上取得了显著提升，在ACC、NMI、F1-score、Precision、Recall、ARI和SC上分别提高了1.32%、4.06%、1.83%、2.32%、1.35%、1.31%和5.99%。scAGCI在PBMC-3k和Mouse-skin数据集上同样效果显著。与scMVAE-NN和scMVAE-POE相比，scAGCI在PBMC-3k数据集上分别提高了5.76%、8.51%、2.59%、4.01%、1.23%、2.42%和0.45%，在Mouse-skin数据集上分别提高了1.68%、0.89%、2.18%、2.02%、2.37%、2.67%和36.72%。scAGCI优异的性能主要得益于其提取特定组学信息、挖掘高阶共享信息以及融合这些信息的能力。而scMCs虽然也考虑了共享信息和特定信息的提取，但忽略了高阶共享信息。其他方法则更多关注从组学中提取和完善特异信息。

(2) scAGCI有效缓解了稀疏性问题。在CellMix数据集上，基于矩阵分解的方法scAI和UnionCom的ARI分别为0.5450和0.6420。使用ZINB解码器重建数据的scMVAE和scMCs方法获得了高于0.8的ARI值，而scAGCI的ARI达到0.9522。较低的ARI表

河北工业大学研究生学位论文中期报告

明这些方法在解决单细胞数据集的稀疏性方面表现不佳。scAGCI通过多视图子空间锚点协同优化方法保留了更好的稀疏性缓解效果，进一步提高了集成嵌入的聚类可区分性。在PBMC和Mouse-skin数据集上也观察到了显著的效果。

3.2.1.5 消融实验

scAGCI 由三个主要模块组成：多视图子空间锚点协同优化模块（MAC）、层次化注意力模块（H-GAT）和共性融合补全模块（CFC）。这三个模块共同有助于 scAGCI 在集成组学信息方面的优异性能（表 3.5-3.7）。在三个数据集上进行了消融实验，以证明该方法中每个模块的有效性。

表3.5 不同模块在CellMix数据集上聚类效果

MAC	H-GAT	CFC	ACC	ARI	NMI
			0.7831	0.7223	0.7852
√			0.9465	0.8346	0.8493
√	√		0.9501	0.8793	0.8646
√	√	√	0.9571	0.9522	0.9479

表3.6 不同模块在PBMC-3k数据集上聚类效果

MAC	H-GAT	CFC	ACC	ARI	NMI
			0.4412	0.3465	0.4474
√			0.5894	0.5579	0.6454
√	√		0.6002	0.5724	0.6529
√	√	√	0.6294	0.6579	0.6963

当仅使用 MAC 模块时，研究结果在 CellMix 上分别提高了 16.34%，11.23%，6.41%。PBMC-3k 数据集上分别提高了 14.82%、21.14%、19.8%，Mouse-skin 指标上分别提升了 11.09%、10.39%、20.45%。结果表明，由 GCN 训练的特异图表示、共享图表示和锚点协同优化有利于提高模型的性能。这主要是由于将基因和峰值等特征信息聚合到节点中，以获得更有代表性的锚点。

河北工业大学研究生学位论文中期报告

表3.7 不同模块在Mouse-skin数据集上聚类效果

MAC	H-GAT	CFC	ACC	ARI	NMI
			0.3827	0.1988	0.2933
✓			0.4936	0.3027	0.4978
✓	✓		0.5414	0.3374	0.5063
✓	✓	✓	0.5631	0.3567	0.5259

当使用 MAC 和 H-GAT 模块。CellMix 上的聚类效果分别 ACC、ARI、NMI 在提高了 0.36%、4.47%、1.53%，PBMC-3k 数据集上的聚类效果分别提高了 1.08%、1.49%、0.75%，在 Mouse-skin 数据集上的聚类效果分别提高了 4.78%、3.47%、0.85%。该模块自适应地探索了峰值与基因之间共享的高阶信息 调整不同邻居的权重，从而提高模型的效果。

同时使用 MAC、H-GAT 和 CFC 三个模块。在三个数据集上，聚类结果平均提高了 1.93%、5.92%和 4.87%。这说明了使用高阶共享信息来完成特定的信息，然后融合它有助于帮助获得更分化的细胞表示，同时保留细胞的共享信息。上述消融结果表明使用所有模块的完整模型具有更好的聚类结果。

3.2.1.6 聚类可视化结果对比

为了展示 scAGCI 在细胞聚类中的独特优势，研究可视化了单组学、特征合并多组学、UnionCom、scAI、scMVAE、scMCs、scAGCI 方法的 UMAP 结果（如图 3.2）。

(1) 在 CellMix 数据集上，原始的 scRNA-seq 数据可以清楚地将大多数细胞聚集成四个细胞簇，但在 BJ、GM 和 H1 细胞边界模糊。原始的 scATAC-seq 数据显示，K562 细胞比其他类型细胞更集中（如图 3.2a scRNA-seq，scATAC-seq）。在 PBMC-3k 和 Mouse-skin 数据集上，尽管聚类边界不清楚，但原始 scRNA-seq 的聚类可以有效地将相似的细胞分组在一起（如图 3.2bc scRNA-seq，scATAC-seq）。然而，在 scATAC-seq 中，直接聚类不能区分细胞类型，只在某些细胞类型中表现出明显的独特性。与单组学数据的聚类结果相比，本文方法 scAGCI 有效地将细胞

河北工业大学研究生学位论文中期报告

聚类合并为一类，且更具鉴别性。




图 3.2 (a) CellMix 的 UMAP 散点图可视化 (b) PBMC-3k 的 UMAP 散点图可视化 (c) Mouse-skin 的 UMAP 散点图可视化

(2)在 CellMix 上的可视化集成方法中，scAI 可以明显区分 GM 和 BJ 细胞，但 H1 和 K562 细胞边界是模糊的。UnionCom、scMVAE 和 scMCs 都能区分出四种细胞类型。相比之下，本文方法得益于多视图空间锚定协同优化模块，以较小的类内

距离将每个细胞类型紧密聚类在一起。在 PBMC- 3k 数据集（如图 3.2b），所有可视化的集成方法都将 B 细胞从其他免疫细胞中分离出来。然而，与 scAI 相比，其他集成方法聚类了三个细胞簇。UnionCom 和 scMVAE 显示 B 细胞、CD14 Mono、CD16 Mono、cDC 和其他 T 细胞之间的类间距离较远。对于 CD4 Naive、CD4 TCM、CD8 Naive 和 CD8 TCM 等细胞亚型，它们均没有得到良好的聚类结果。相反，本文方法清晰地区分了这些细胞亚型。

3.2.1.7 运行时间对比

考虑到单细胞测序数据集规模的不断扩大，本文在不同大小的数据集上记录每种方法的时间消耗。如表 3.8 所示，在 CellMix 数据集上，UnionCom 的运行时间最短，其次是本文方法 scAGCI，而 scAI 消耗的时间最多。在 PBMC 数据集上，scAGCI 运行时间最短，其次是 UnionCom 算法。在 Mouse-skin 数据集上，UnionCom 不能在大规模数据集上运行，而 scAGCI 运行时间最短。在小数据集（Cellmix）中，基于矩阵分解的 UnionCom 运行时更具优势，但该方法的聚类效果更好。对于中、大数据集（PBMC-3k 和 Mouse-skin），scAGCI 在运行时和聚类效果方面具有明显的优势。

表3.8 不同规模数据集运行时间

	CellMix	PBMC-3k	Mouse-skin
UnionCom	0.98	5.55	NA
scAI	25.47	30.59	635.18
scMVAE	2.76	5.43	162.65
scMCs	3.6	6.86	181.65
scAGCI	1.01	2.76	150.924

3.2.1.8 单细胞多组学下游任务

scRNA-seq 捕获转录谱来揭示基因表达模式，本文利用人类的 PBMC 数据集进行说明。研究在提取的 scRNA-seq 特异性信息中，选择每个细胞簇与其他细胞之间差异

最大的前 2 个基因作为候选基因（如图 3.3A, B）可见仅 scRNA-seq 的组学特异性信息模糊了 CD4 TCM 和 Treg 细胞、B intermediate 和 B memory 细胞之间的边界，这也在单组学可视化中有所体现。在 KEGG 通路分析中（如图 3.3C），原发性免疫缺陷和 T 细胞受体信号通路可能与在 BP 中提到的免疫反应、炎症反应相对应。此外，KEGG 通路分析中展示了基因在造血细胞谱系、细胞粘附分子、抗原加工和呈递的富集效果。




图 3.3 PBMC 数据集上 scRNA-seq 分析

(a) 不同细胞簇中前 2 个标记基因的表达 (b) 不同细胞类型中前 2 个标记基因的表达分布情况 (c) KEGG 通路的富集分析 (d) Go 的富集情况

PBMC 数据集的 GO 富集分析（如图 3.3D）展示了一些结果：在质膜中富集的细胞成分项、膜的完整成分和受体复合物。在生物过程中，在信号转导和细胞表面受体信号传导中检测到显著的富集。此外，免疫反应、炎症反应和细胞质翻译也可以从结果中看到。这些发现共同表明，该数据集中的基因在细胞膜和受体相关活动和免疫反应中发挥着关键作用。




图 3.4 ChromVAR 计算细胞的转录因子评分 (a)原始数据(b) 提取到 scATAC-seq

scATAC-seq 阐明了染色质区域的可及性，反映了控制基因表达的调控元件。为了进一步说明 scAGCI 方法的生物可解释性和细胞鉴别性，本文计算了原始和提取的 scATAC-seq 特异性组学数据的转录因子活性评分。PBMC 的原始数据大致将 14 种细胞分为 3 种类型，三种 B 细胞、记忆细胞和 T 细胞等。cDC2 和 pDC 细胞在转录因子 SPI1 和 SPIC 上与其他细胞明显不同，且在其他聚类方法中与其他细胞距离较远。另一方面，B 细胞在 REL、RELA 中有更高的活性分数，而记忆细胞在 SPDEF 转录因子中的活性水平则远低于其他类型的细胞。CD16 Mono 在 SPI1 和 SPIB 上的表达量略高于 CD14 Mono。最后，在 T 细胞中，转录因子 SPDEF 高表达，而 Naive 细胞在 FOS 和 JUN 上的得分低于 TCM 细胞^{[53][54]}。因此，scAGCI 可以进一步区分了 CD14 Mono、CD16 Mono、CD4 Naive、CD4 TCM、CD8 Naive 和 CD8 TCM 细胞。

3.2.2 课题阶段性成果

IEEE Journal of Biomedical and Health Informatics(SCI 2区Top)在投小论文一篇。

四、存在的主要问题和后续工作思路

4.1 研究中存在的主要问题

通过现有的研究结果可知，对数据中细胞-细胞，基因-基因，基因-峰，峰-峰之间的关系提取和挖掘有益于细胞聚类任务。虽然本研究通过多视图锚学习的方法提取了

河北工业大学研究生学位论文中期报告

组学特异和共享信息，既提高聚类效果又降低计算时间。但对不匹配数据集中相同细胞类型，但不同细胞测序的特征捕获依然欠缺，缺少对新细胞类型的发现。

4.2 后续工作思路

后续的工作主要从不匹配scRNA-seq和scATAC-seq的匹配和生物特征提取二者相结合的角度入手，利用现有的生物特征网络的调节关系和锚点图卷积网络的优势，在模型中匹配scRNA-seq和scATAC-seq，解决scRNA-seq和scATAC-seq中存在细胞或细胞类型不一致的情况。

五、预期目标与下一步工作计划

5.1 预期目标

针对以上研究存在的问题，下一步研究预期利用现有的生物特征网络的调节关系去匹配scRNA-seq和scATAC-seq数据集，利用图卷积网络捕捉不同组学数据的特性，进一步提高模型效果。

5.2 下一步工作安排

2024年6月-2024年11月：利用现有的生物特征网络的调节关系去匹配scRNA-seq和scATAC-seq数据集，结合图卷积网络优势去提取数据集的生物信息。

2024年12月-2025年3月：对于模型进行优化及改进，同时撰写完成大论文。

2025年3月-2025年5月：总结课题研究成果，补充相关细节，完善实验，对大论文内容进行修正，准备毕业答辩。

参考文献

- [1] Rappoport N and Shamir R. Multi-omic and multi-view clustering algorithms: review and cancer benchmark[J]. *Nucleic Acids Research*, 2018, 46(20): 10546-10562.
- [2] 荣志炜. 基于多组学数据的细胞识别方法、装置、设备及存储介质: CN202410259151.2[P]. 2024-05-21.
- [3] Xu Y, McCord R P. Diagonal integration of multimodal single-cell data: potential pitfalls and paths forward[J]. *Nature Communications*, 2022, 13(1): 3505-3517.
- [4] 王欣,陈磊. 单细胞测序揭示结直肠印戒细胞癌的细胞和分子生物学特征[J]. *现代免疫学*, 2024, 44(03):185-196.
- [5] 王小聪, 李明. 单细胞测序在口腔鳞状细胞癌研究中的价值[J]. *中国癌症杂志*, 2024, 34(05): 501-508.
- [6] 吕晓烁. 单细胞测序联合多组学技术解析动脉粥样硬化中血管平滑肌细胞向成骨表型转化的调控机制[D]. 北京: 北京协和医学院, 2023: 22-25.
- [7] Molho D, Ding J, Tang W, et al. Deep learning in single-cell analysis[J]. *ACM Transactions on Intelligent Systems and Technology*, 2022, 15(3): 1-62.
- [8] Butler A, Hoffman P, Smibert P, et al. Integrating single-cell transcriptomic data across different conditions, technologies, and species[J]. *Nature Biotechnology*, 2018, 36(5): 411-420.
- [9] Wu W and Ma X. Network-based structural learning nonnegative matrix factorization algorithm for clustering of scRNA-seq data[J]. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 2022, 20(1): 566-575.
- [10] Argelaguet R, Arnol D, Bredikhin D, et al. MOFA+: a statistical framework for comprehensive integration of multi-modal single-cell data[J]. *Genome Biology*, 2020, 21(111): 1-17.
- [11] Jin S, Zhang L, Nie Q. scAI: an unsupervised approach for the integrative analysis of parallel single-cell transcriptomic and epigenomic profiles[J]. *Genome Biology*, 2020, 21(25): 1-19.
- [12] Hao Y, Hao S, Andersen-Nissen E, et al. Integrated analysis of multimodal single-cell data[J]. *Cell*, 2021, 184(13): 3573-3587.
- [13] Zamanighomi M, Lin Z, Daley T, et al. Unsupervised clustering and epigenetic classification of single cells[J]. *Nature Communications*, 2018, 9(1): 2410-2423.
- [14] Welch J D, Kozareva V, Ferreira A, et al. Single-cell multi-omic integration compares and contrasts features of brain cell identity[J]. *Cell*, 2019, 177(7): 1873-1887.
- [15] Cao K, Bai X, Hong Y. et al. Unsupervised topological alignment for single-cell multi-omics integration[J]. *Bioinformatics*, 2020, 36(1): i48-i56.
- [16] Zuo C, Dai H and Chen L. Deep cross-omics cycle attention model for joint analysis of single-cell

河北工业大学研究生学位论文中期报告

- multi-omics data[J]. *Bioinformatics*, 2021, 37(22): 4091-4099.
- [17] Zuo C and Chen L. Deep-joint-learning analysis model of single cell transcriptome and open chromatin accessibility data[J]. *Briefings in Bioinformatics*, 2021, 22(4): 1-13.
- [18] Li G, Fu S, Wang S, et al. A deep generative model for multi-view profiling of single-cell RNA-seq and ATAC-seq data[J]. *Genome Biology*, 2022, 23(1): 20-42.
- [19] Ren L, Wang J, Li Z, et al. scMCs: a framework for single-cell multi-omics data integration and multiple clusterings[J]. *Bioinformatics*, 2023, 39(4): 1-7.
- [20] Wen H, Ding J, Jin W, et al. Graph neural networks for multimodal single-cell data integration[C]. *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. Washington: KDD, 2022: 4153-4163.
- [21] Cao Z J and Gao G. Multi-omics single-cell data integration and regulatory inference with graph-linked embedding[J]. *Nature Biotechnology*, 2022, 40(10): 1458-1466.
- [22] Karlsson M, Janzén D L, Durrieu, L, et al. Nonlinear mixed-effects modelling for single cell estimation: when, why, and how to use it[J]. *BMC Systems Biology*, 2015, 9(52): 1-15.
- [23] Liu L, Liu C, Quintero A, et al. Deconvolution of single-cell multi-omics layers reveals regulatory heterogeneity[J]. *Nature Communications*, 2019, 10(1): 470-477.
- [24] Eraslan G, Simon L M, Mircea M, et al. Single-cell RNA-seq denoising using a deep count autoencoder[J]. *Nature Communications*, 2019, 10(1): 390-402.
- [25] Wani S A, Khan S A, Quadri S M K. scJVAE: a novel method for integrative analysis of multimodal single-cell data[J]. *Computers in Biology and Medicine*, 2023, 158: 1-16.
- [26] Lewsey J D and Thomson W M. The utility of the zero - inflated Poisson and zero - inflated negative binomial models: a case study of cross - sectional and longitudinal DMF data examining the effect of socio-economic status[J]. *Community Dentistry and Oral Epidemiology*, 2004, 32(3): 183-189.
- [27] Athaya T, Ripan R C, Li X, et al. Multimodal deep learning approaches for single-cell multi-omics data integration[J]. *Briefings in Bioinformatics*, 2023, 24(5): 1-15.
- [28] Xu Y, Das P and McCord R P. SMILE: mutual information learning for integration of single-cell omics data[J]. *Bioinformatics*, 2022, 38(2): 476-486.
- [29] Yang M, Yang Y, Xie C, et al. Contrastive learning enables rapid mapping to multimodal single-cell atlas of multimillion scale[J]. *Nature Machine Intelligence*, 2022, 4(8): 696-709.
- [30] Liu X, Zhang F, Hou Z, et al. Self-supervised learning: generative or contrastive[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2021, 35(1): 857-876.
- [31] Song Q, Su J and Zhang W. scGCN is a graph convolutional networks algorithm for knowledge transfer in single cell omics[J]. *Nature Communications*, 2021, 12(1): 1-11.
- [32] Ding C, Sun S and Zhao J. MST-GAT: a multimodal spatial-temporal graph attention network for

河北工业大学研究生学位论文中期报告

- time series anomaly detection[J]. *Information Fusion*, 2023, 89(1): 527-536.
- [33] Ma A, Wang X, Li J, et al. Single-cell biological network inference using a heterogeneous graph transformer[J]. *Nature Communications*, 2023, 14(1): 1-18.
- [34] Lähnemann D, Köster J, Szczurek E, et al. Eleven grand challenges in single-cell data science[J]. *Genome Biology*, 2020, 21:1-35.
- [35] Kopf J, Zeileis A and Strobl C. Anchor selection strategies for DIF analysis: Review, assessment, and new approaches[J]. *Educational and Psychological Measurement*, 2015, 75(1): 22-56.
- [36] Wang J, Ma Z, Nie F, et al. Fast self-supervised clustering with anchor graph[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2021, 33(9): 4199-4212.
- [37] Yang H, Gao Q, Xia W, et al. Multiview spectral clustering with bipartite graph[J]. *IEEE Transactions on Image Processing*, 2022, 31: 3591-3605.
- [38] Qiang Q, Zhang B, Wang F, et al. Fast multi-view discrete clustering with anchor graphs[C]. *Proceedings of the AAAI Conference on Artificial Intelligence*. Palo Alto: AAAI Press, 2021: 9360-9367.
- [39] You J, Ren Z, You X, et al. Priori anchor labels supervised scalable multi-view bipartite graph clustering[C]. *Proceedings of the AAAI Conference on Artificial Intelligence*. Washington: AAAI Press, 2023: 10972-10979.
- [40] You J, Hou Y, Ren Z, et al. Cluster center consistency guided sampling learning for multiple kernel clustering [J]. *Information Science*, 2022, 606(2022): 410-422.
- [41] Liu S, Wang S, Zhang P, et al. Efficient one-pass multi-view subspace clustering with consensus anchors[C]. *Proceedings of the AAAI Conference on Artificial Intelligence*. Palo Alto: AAAI Press, 2022: 7576-7584.
- [42] Wei N, Nie Y, Liu L, et al. Secuer: ultrafast, scalable and accurate clustering of single-cell RNA-seq data[J]. *PLOS Computational Biology*, 2022, 18(12): 1-20.
- [43] Ahmed M, Seraj R and Islam S M S. The k-means algorithm: a comprehensive survey and performance evaluation[J]. *Electronics*, 2020, 9(8): 1-12.
- [44] Kipf T N and Welling M. Semi-supervised classification with graph convolutional networks[C]. *5th International Conference on Learning Representations*. Toulon: ICLR, 2017: 1-14.
- [45] Bica AM, Căuş VA, Fechet I, et al. Application of the Cauchy-Buniakovski-Schwarz s Inequality to an Optimal Property for Cubic Splines[J]. *Journal of Computational Analysis & Applications*, 2007, 9(1): 43.
- [46] Chen S, Lake B B and Zhang K. High-throughput sequencing of the transcriptome and chromatin accessibility in the same cell[J]. *Nature Biotechnology*, 2019, 37(12): 1452-1457.
- [47] Hao Y, Hao S, Andersen-Nissen E, et al. Integrated analysis of multimodal single-cell data[J]. *Cell*, 2021, 184(13): 3573-3587.

河北工业大学研究生学位论文中期报告

- [48] Ma S, Zhang B, LaFave LM, et al. Chromatin potential identified by shared single-cell profiling of RNA and chromatin[J]. *Cell*, 2020, 183(4): 1103-1116.
- [49] 余忆琳. 基于一致性矩阵评分的单细胞聚类算法[D]. 济南: 山东大学, 2023:34-38.
- [50] 段然. 基于组学数据集成的癌症亚型识别研究[D]. 西安: 西安电子科技大学, 2023: 48-53.
- [51] Wang J, Sun Z and Lin Z. scAMACE: model-based approach to the joint analysis of single-cell data on chromatin accessibility, gene expression and methylation[J]. *Bioinformatics*, 2021, 37 (21): 3874-3880.
- [52] Ma Y, Sun Z, Zeng P, et al. JSNMF enables effective and accurate integrative analysis of single-cell multiomics data[J]. *Briefings in Bioinformatics*, 2022, 23(3): 1-13.
- [53] Ji A L, Rubin A J, Thrane K, et al. Multimodal analysis of composition and spatial architecture in human squamous cell carcinoma[J]. *Cell*, 2020, 182(2): 497-514.
- [54] Zhu B, Chen S, Bai Y, et al. Robust single-cell matching and multimodal analysis using shared and distinct features[J]. *Nature Methods*, 2023, 20(2): 304-315.